ĐẠI HỌC KINH TẾ QUỐC DÂN

VIỆN ĐÀO TẠO TIÊN TIẾN, CLC & POHE



BÀI TẬP NHÓM

Học phần: Khoa học dữ liệu

PHÂN TÍCH DỮ LIỆU
BANK MARKETING

Nhóm thực hiện: 22
Lớp học phần: AEP.TOKT1138.LS(126)_01
Giảng viên: Trần Đức Minh

STT	Họ và tên	Mã số sinh viên
1	Nguyễn Vũ Thanh Tú	11246984
2	Dương Hồng Nhung	11241104
3	Trần Yến Nhi	11245666
4	Nguyễn Hà My	11247694
5	Cao Ngọc Minh	11243222

Mã nguồn GitHub: `https://github.com/duongdong297/Mid-Term-2-NEU`

HÀ NỘI, 11/2026

MỤC LỤC

Chương 1. Thu thập và đánh giá dữ liệu ban đầu **1**
1.1 Bối cảnh và mục tiêu phân tích 1
1.2 Tổng quan dữ liệu 1
1.3 Mô tả biến dữ liệu 2
1.4 Kiểm tra chất lượng dữ liệu 3

Chương 2. Tiền xử lý và làm sạch dữ liệu **5**
2.1 Kiểm tra miền giá trị và bản ghi trùng 5
2.2 Cách xử lý giá trị chưa xác định 5
2.3 Nhận diện ngoại lệ bằng IQR 6
2.4 Tạo biến phục vụ phân tích 7

Chương 3. Phân tích và trực quan hóa **8**
3.1 Cách tính tỷ lệ và kiểm định 8
3.2 Phân bố kết quả đăng ký 8
3.3 Tỷ lệ đăng ký theo nhóm tuổi 9
3.4 Tỷ lệ đăng ký theo tình trạng vay nhà 11
3.5 Kết quả campaign trước và đăng ký hiện tại 12
3.6 Số dư theo kết quả đăng ký 13

Chương 4. Đánh giá tác động và khuyến nghị **14**
4.1 Tóm tắt các phát hiện 14
4.2 Đề xuất thử nghiệm cho chiến dịch sau 14
4.2.1 Thử thông điệp theo nhóm tuổi và tình trạng vay nhà . . . 14
4.2.2 Thử liên hệ lại khách hàng từng có kết quả thành công . . 15
4.2.3 Đo hiệu quả trước khi mở rộng 15
4.3 Giới hạn của dữ liệu và phân tích 15
4.4 Hướng mở rộng và khả năng tái lập 16
4.5 Kết luận 16

TÀI LIỆU THAM KHẢO **17**

DANH MỤC BẢNG BIỂU

1.1 Thông tin tổng quan về dữ liệu 1
1.2 Danh mục thuộc tính của file dữ liệu 2
1.3 Số lượng và tỷ lệ nhãn unknown 3
1.4 Thống kê mô tả các cột số 3

2.1 Kết quả kiểm tra miền giá trị và trùng lặp 5
2.2 Ngoại lệ theo ngưỡng IQR 6

3.1 Số lượng và tỷ lệ đăng ký 8
3.2 Kết quả đăng ký theo nhóm tuổi 9
3.3 Kiểm định chi-square giữa nhóm tuổi và đăng ký 10
3.4 Kết quả đăng ký theo tình trạng vay nhà 11
3.5 Kiểm định chi-square giữa vay nhà và đăng ký 11
3.6 Kết quả đăng ký theo kết quả campaign trước 12
3.7 Các phân vị số dư theo kết quả đăng ký 13

4.1 Các phát hiện chính và ý nghĩa khi áp dụng 14

DANH MỤC HÌNH VẼ

2.1 Histogram và boxplot của số dư 6

3.1 Số bản ghi theo kết quả đăng ký 9
3.2 Tỷ lệ đăng ký theo nhóm tuổi 10
3.3 Tỷ lệ đăng ký theo tình trạng vay nhà 11
3.4 Tỷ lệ đăng ký theo kết quả chiến dịch trước 12
3.5 Boxplot số dư theo kết quả đăng ký 13

Chương 1. Thu thập và đánh giá dữ liệu ban đầu

1.1 Bối cảnh và mục tiêu phân tích

Trong chiến dịch marketing tiền gửi, ngân hàng cần tìm hiểu những nhóm khách hàng có tỷ lệ đăng ký khác nhau để lựa chọn hướng thử nghiệm phù hợp. Dữ liệu Bank Marketing chứa thông tin cá nhân, tình trạng tài chính, thông tin liên hệ và kết quả đăng ký. Biến kết quả là `deposit`, nhận giá trị `yes` khi đăng ký và `no` khi không đăng ký.

Mục tiêu của bài là mô tả chất lượng dữ liệu, so sánh tỷ lệ đăng ký theo nhóm tuổi, tình trạng vay nhà và kết quả chiến dịch trước; đồng thời xem xét số dư giữa hai nhóm đăng ký và không đăng ký. Từ những kết quả này, nhóm đề xuất các thử nghiệm cho chiến dịch sau. Phạm vi bài gồm thống kê mô tả, trực quan hóa và kiểm định chi-square, chưa xây dựng mô hình dự báo hoặc xác định chiến lược tối ưu.

1.2 Tổng quan dữ liệu

Nhóm sử dụng file `bank.csv` được cung cấp cho đề số 2, có nguồn Bank Marketing Dataset trên Kaggle [1]. File có 11.162 dòng và 17 cột. Mỗi dòng là một bản ghi chứa thông tin khách hàng và kết quả chiến dịch; dữ liệu không có mã khách hàng để xác minh mỗi dòng thuộc một người riêng biệt.

Chỉ có một file dữ liệu được sử dụng nên không thực hiện nối bảng bằng khóa chính hoặc khóa ngoại. Các bảng và biểu đồ trong báo cáo được tính từ cùng file CSV bằng notebook `Mid-term-2-Bank-Marketing.ipynb` [2]. Quy trình gồm bốn giai đoạn theo yêu cầu của đề.

Bảng 1.1: Thông tin tổng quan về dữ liệu

Tiêu chí	Kết quả
File đầu vào	`bank.csv`
Số quan sát và thuộc tính	11.162 dòng, 17 cột
Cột số nguyên	7 cột
Cột phân loại dạng chuỗi	10 cột
Biến kết quả	`deposit`: `yes`, `no`
Phạm vi phân tích	Tỷ lệ đăng ký trong mẫu và khác biệt giữa các nhóm

Bảng 1.1 cho thấy phần lớn thuộc tính là biến phân loại. Vì vậy, bài sử dụng bảng tần số và tỷ lệ theo nhóm cho các biến này. Các biến số được xem xét thêm bằng phân vị và biểu đồ phân phối.

1.3 Mô tả biến dữ liệu

Bảng 1.2 mô tả 17 thuộc tính. Kiểu số nguyên là kiểu lưu trữ trong file; một số cột như ngày hoặc tháng vẫn cần được đọc theo ý nghĩa thời gian, không dùng như các đại lượng tài chính.

Bảng 1.2: Danh mục thuộc tính của file dữ liệu

Thuộc tính	Kiểu	Ý nghĩa và lưu ý
`age`	Số nguyên	Tuổi khách hàng; trong mẫu từ 18 đến 95.
`job`	Chuỗi	Nghề nghiệp; có nhãn `unknown`.
`marital`	Chuỗi	Tình trạng hôn nhân: `married`, `single`, `divorced`.
`education`	Chuỗi	Trình độ học vấn; có nhãn `unknown`.
`default`	Chuỗi	Tình trạng vỡ nợ tín dụng, ghi bằng `yes`/`no`.
`balance`	Số nguyên	Số dư tài khoản; có cả giá trị âm. Báo cáo giữ đơn vị gốc, không quy đổi tiền tệ.
`housing`	Chuỗi	Có khoản vay nhà hay không, ghi bằng `yes`/`no`.
`loan`	Chuỗi	Có khoản vay cá nhân hay không, ghi bằng `yes`/`no`.
`contact`	Chuỗi	Hình thức liên hệ: `cellular`, `telephone`, `unknown`.
`day`	Số nguyên	Ngày liên hệ trong tháng.
`month`	Chuỗi	Tháng liên hệ, lưu bằng tên tháng viết tắt.
`duration`	Số nguyên	Thời lượng cuộc gọi; chỉ có sau cuộc gọi.
`campaign`	Số nguyên	Số lần liên hệ trong chiến dịch hiện tại.
`pdays`	Số nguyên	Số ngày từ lần liên hệ ở chiến dịch trước; -1 biểu thị chưa được liên hệ trước đó.
`previous`	Số nguyên	Số lần liên hệ trước chiến dịch hiện tại.

Thuộc tính	Kiểu	Ý nghĩa và lưu ý
poutcome	Chuỗi	Kết quả chiến dịch trước: success, failure, other, unknown.
deposit	Chuỗi	Kết quả đăng ký tiền gửi: yes hoặc no.

Biến duration chỉ được biết sau khi kết thúc cuộc gọi. Nếu lựa chọn khách hàng trước khi gọi, thông tin này chưa có sẵn. Vì vậy, bài không dùng thời lượng cuộc gọi để đưa ra đề xuất chọn khách hàng.

1.4 Kiểm tra chất lượng dữ liệu

Nhóm dùng info(), isna(), duplicated() và bảng thống kê mô tả để kiểm tra cấu trúc. Cả 17 cột đều có 11.162 giá trị khác null, tỷ lệ null bằng 0%. Không có dòng trùng hoàn toàn. Tuy nhiên, một số cột có nhãn unknown, cần được phân biệt với ô trống hoặc giá trị null.

Bảng 1.3: Số lượng và tỷ lệ nhãn unknown

Thuộc tính	Số dòng unknown	Tỷ lệ (%)
job	70	0,63
education	497	4,45
contact	2.346	21,02
poutcome	8.326	74,59

Tỷ lệ unknown cao nhất ở poutcome, tiếp đến là contact. Do đó, kết luận không có null chỉ phản ánh cách lưu trữ; chưa đồng nghĩa mọi thuộc tính đều có thông tin xác định. Mỗi tỷ lệ ở Bảng 1.3 được tính trên tổng 11.162 dòng; không cộng các tỷ lệ này vì một dòng có thể chứa nhiều nhãn unknown.

Bảng 1.4: Thống kê mô tả các cột số

Biến	Nhỏ nhất	Q1	Trung vị	Q3	Lớn nhất
age	18	32	39	49	95
balance	-6.847	122	550	1.708	81.204
day	1	8	15	22	31
duration	2	138	255	496	3.881
campaign	1	1	2	3	63
pdays	-1	-1	-1	20,75	854
previous	0	0	0	1	58

Tuổi trung vị là 39. Số dư dao động từ -6.847 đến 81.204, rộng hơn nhiều so với khoảng giữa Q1 = 122 và Q3 = 1.708. Số lần liên hệ hiện tại có trung vị 2 nhưng lớn nhất là 63. Đây là những dấu hiệu cần xem xét phân phối và ngoại lệ ở Chương 2. Riêng `pdays`, giá trị -1 là mã quy ước, nên không diễn giải là số ngày âm hoặc tự coi là dữ liệu lỗi.

Chương 2. Tiền xử lý và làm sạch dữ liệu

2.1 Kiểm tra miền giá trị và bản ghi trùng

Nhóm kiểm tra nhãn của `deposit`, tuổi, ngày liên hệ và giá trị âm của `pdays`. Khoảng tuổi từ 18 đến 100 được dùng làm mốc rà soát trong bài, không phải quy tắc chung để xóa dữ liệu.

Bảng 2.1: Kết quả kiểm tra miền giá trị và trùng lặp

Nội dung kiểm tra	Số dòng
Tuổi ngoài khoảng từ 18 đến 100	0
Ngày ngoài khoảng từ 1 đến 31	0
`pdays` nhỏ hơn -1	0
`pdays` bằng -1	8.324
Dòng trùng hoàn toàn	0
Số dòng sau làm sạch	11.162

Các giá trị được kiểm tra không vượt ngoài miền đã đặt, ngoại trừ mã -1 của `pdays` có ý nghĩa riêng. Biến `deposit` chỉ có hai nhãn `yes` và `no`. Bước `drop_duplicates()` không làm giảm số dòng vì không có dòng trùng hoàn toàn. Kiểm tra này chưa loại trừ khả năng một khách hàng xuất hiện ở nhiều bản ghi khác nhau.

2.2 Cách xử lý giá trị chưa xác định

Nhóm giữ `unknown` thành một nhóm riêng để trình bày đúng thông tin đang có. Việc thay nhãn này bằng giá trị phổ biến nhất sẽ gán thông tin chưa được xác minh cho khách hàng. Do không có null trong file, bài không thực hiện điền thiếu bằng trung bình hoặc trung vị.

Với `poutcome`, trong 8.326 dòng `unknown` có 8.324 dòng mang `pdays = -1`. Các dòng này chưa được liên hệ trong chiến dịch trước. Hai dòng còn lại có `pdays` khác -1 nhưng kết quả trước chưa xác định. Vì vậy, phần lớn nhãn `unknown` ở cột này tương ứng với chưa có lịch sử liên hệ trước, cần phân biệt với thiếu ghi nhận kết quả.

2.3 Nhận diện ngoại lệ bằng IQR

Khoảng tứ phân vị được tính bằng:

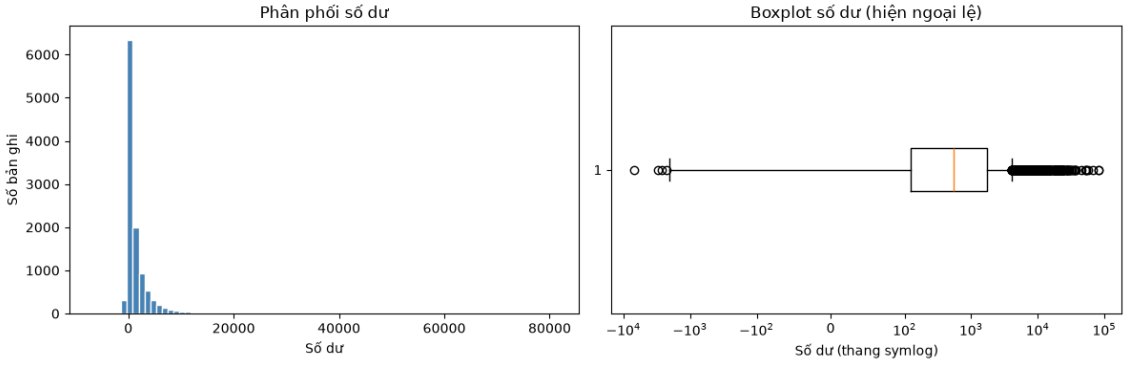
$$IQR = Q_3 - Q_1.$$

Các điểm nhỏ hơn $Q_1 - 1{,}5 \times IQR$ hoặc lớn hơn $Q_3 + 1{,}5 \times IQR$ được đánh dấu để xem xét. IQR dựa trên phân vị nên ít chịu ảnh hưởng của giá trị cực đoan. Phương pháp này phù hợp để mô tả vị trí các điểm nằm xa phần giữa phân phối, nhưng chưa đủ để kết luận chúng là dữ liệu sai.

Bảng 2.2: Ngoại lệ theo ngưỡng IQR

Biến	Ngưỡng dưới	Ngưỡng trên	Số điểm	Tỷ lệ (%)
`age`	6,5	74,5	171	1,53
`balance`	-2.257	4.087	1.055	9,45
`duration`	-399	1.033	636	5,70
`campaign`	-2	6	601	5,38

Số dư có tỷ lệ nằm ngoài IQR cao nhất trong bốn biến, đạt 9,45%. Với tuổi, ngưỡng trên là 74,5 nên những tuổi lớn hơn ngưỡng này được đánh dấu, dù vẫn có thể hợp lệ. Tương tự, số lần liên hệ trên 6 được xem là ngoại lệ theo phân phối trong mẫu, chưa phải lỗi ghi nhận. Các tỷ lệ trong Bảng 2.2 được tính riêng cho từng biến; một dòng có thể được đánh dấu ở nhiều biến.



Hình 2.1: Histogram và boxplot của số dư

Histogram ở Hình 2.1 cho thấy số dư tập trung ở vùng giá trị thấp và có đuôi kéo dài bên phải. Trung bình khoảng 1.529 cao hơn trung vị 550; giá trị lớn nhất là 81.204. Các giá trị lớn có ảnh hưởng đến trung bình, nên bài dùng thêm trung vị khi so sánh số dư giữa các nhóm.

Boxplot hiển thị các điểm ngoài râu và dùng thang `symlog` để giữ cả số âm và số dương lớn. Thang này tuyến tính gần 0 và nén các giá trị có độ lớn cao, nên khoảng cách trên trục không đồng đều như thang tuyến tính. Có 1.055 điểm ngoài ngưỡng IQR. Nhóm giữ các điểm này vì số dư âm hoặc lớn vẫn có thể hợp lệ.

2.4 Tạo biến phục vụ phân tích

Biến `deposit_yes` nhận giá trị 1 nếu `deposit = yes` và 0 nếu `deposit = no`. Trung bình của biến này trong một nhóm chính là tỷ lệ đăng ký. Tuổi được chia thành năm nhóm: không quá 30, từ 31 đến 40, từ 41 đến 50, từ 51 đến 60 và trên 60. Cách chia giúp so sánh các khoảng tuổi dễ đọc; kết quả vẫn phụ thuộc vào ranh giới nhóm đã chọn.

Bài không chuẩn hóa các biến số và không mã hóa toàn bộ biến phân loại vì chưa huấn luyện mô hình. Sau tiền xử lý, dữ liệu vẫn có 11.162 dòng và được bổ sung hai cột phục vụ phân tích. Các thuộc tính gốc và giá trị ngoại lệ được giữ nguyên.

Chương 3. Phân tích và trực quan hóa

3.1 Cách tính tỷ lệ và kiểm định

Với mỗi nhóm khách hàng, tỷ lệ đăng ký được tính bằng:

$$\text{Tỷ lệ đăng ký (\%)} = \frac{\text{Số bản ghi có deposit = yes}}{\text{Tổng số bản ghi trong nhóm}} \times 100.$$

Các biểu đồ cột dùng để so sánh số lượng hoặc tỷ lệ giữa các nhóm. Boxplot được dùng để so sánh vị trí trung tâm và mức phân tán của số dư.

Nhóm kiểm định hai giả thuyết về tuổi và tình trạng vay nhà. Với mỗi cặp biến, H_0 là kết quả đăng ký độc lập với biến phân nhóm; H_1 là hai biến có mối liên hệ. Dùng mức ý nghĩa $\alpha = 0{,}05$ và bác bỏ H_0 khi p-value nhỏ hơn 0,05. Thống kê kiểm định có dạng:

$$\chi^2 = \sum \frac{(O-E)^2}{E},$$

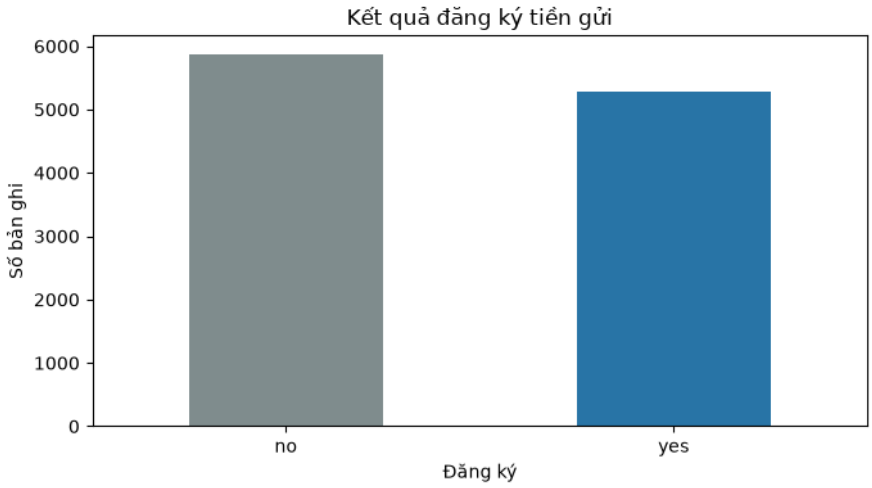
trong đó O là tần số quan sát và E là tần số kỳ vọng nếu hai biến độc lập. Notebook dùng `chi2_contingency` với thiết lập mặc định; bảng 2×2 về vay nhà có hiệu chỉnh liên tục Yates. Các kết luận chỉ phản ánh mối liên hệ; dữ liệu không có mã khách hàng để xác minh điều kiện độc lập giữa các dòng.

3.2 Phân bố kết quả đăng ký

Bảng 3.1: Số lượng và tỷ lệ đăng ký

Kết quả	Số bản ghi	Tỷ lệ (%)
Không đăng ký (`no`)	5.873	52,6
Đăng ký (`yes`)	5.289	47,4
Tổng	11.162	100,0

Bảng 3.1 cho thấy nhóm không đăng ký nhiều hơn nhóm đăng ký 584 bản ghi. Hai nhóm có quy mô tương đối gần nhau trong mẫu.



Hình 3.1: Số bản ghi theo kết quả đăng ký

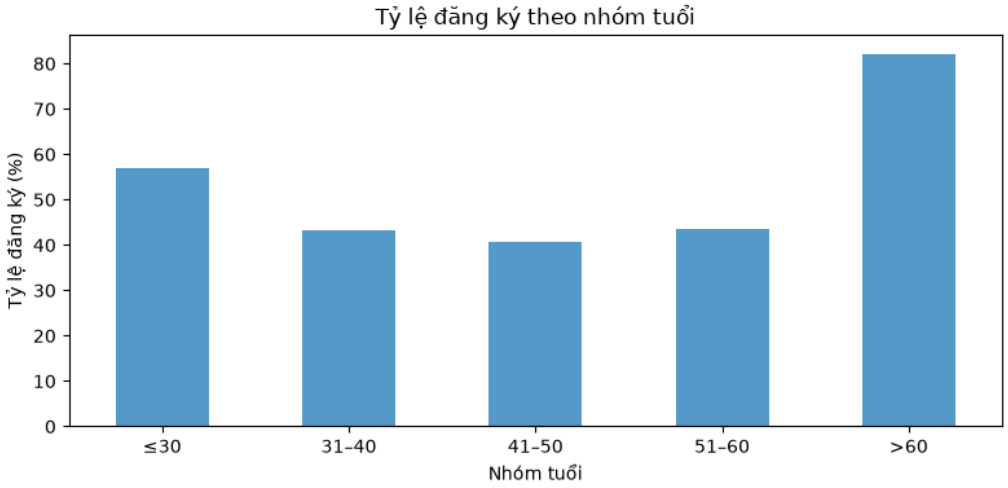
Cột `no` ở Hình 3.1 cao hơn cột `yes`, phù hợp với bảng số lượng. Tỷ lệ đăng ký 47,4% được dùng làm mốc so sánh trong bài. Chưa thể xem đây là tỷ lệ của toàn bộ khách hàng hoặc hiệu quả của chiến dịch mới vì chưa xác minh cách chọn mẫu.

3.3 Tỷ lệ đăng ký theo nhóm tuổi

Bảng 3.2: Kết quả đăng ký theo nhóm tuổi

Nhóm tuổi	Số bản ghi	Số đăng ký	Tỷ lệ (%)
Không quá 30	2.007	1.145	57,1
Từ 31 đến 40	4.188	1.812	43,3
Từ 41 đến 50	2.496	1.019	40,8
Từ 51 đến 60	1.860	811	43,6
Trên 60	611	502	82,2

Nhóm trên 60 có tỷ lệ cao nhất nhưng số bản ghi ít nhất. Nhóm từ 31 đến 40 có nhiều bản ghi nhất và cũng có số đăng ký lớn nhất (1.812), dù tỷ lệ chỉ đạt 43,3%. Điều này cho thấy thứ hạng về tỷ lệ và số lượng đăng ký có thể khác nhau.



Hình 3.2: Tỷ lệ đăng ký theo nhóm tuổi

Hình 3.2 cho thấy tỷ lệ không tăng đều theo tuổi. Nhóm không quá 30 đạt 57,1%, ba nhóm từ 31 đến 60 nằm trong khoảng 40,8% đến 43,6%, còn nhóm trên 60 đạt 82,2%. Chênh lệch giữa nhóm cao nhất và thấp nhất khoảng 41,3 điểm phần trăm, tính từ tỷ lệ chưa làm tròn. Cần đọc các tỷ lệ cùng quy mô mẫu ở Bảng 3.2.

Bảng 3.3: Kiểm định chi-square giữa nhóm tuổi và đăng ký

Chỉ tiêu	Giá trị
Thống kê χ^2	453,82
Bậc tự do	4
P-value	$6{,}48 \times 10^{-97}$
Tần số kỳ vọng nhỏ nhất	289,5
Mức ý nghĩa	0,05

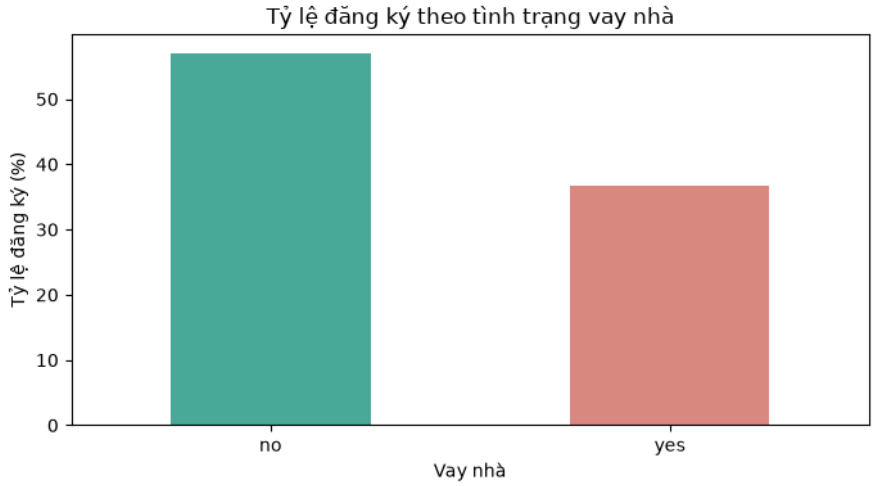
Tần số kỳ vọng nhỏ nhất lớn hơn 5. P-value nhỏ hơn 0,05 nên bác bỏ H_0: có bằng chứng thống kê về mối liên hệ giữa nhóm tuổi và kết quả đăng ký trong mẫu. Kết quả này chưa cho biết tuổi là nguyên nhân tạo ra khác biệt, vì các đặc điểm khác của khách hàng chưa được kiểm soát và tính độc lập giữa các bản ghi chưa được xác minh.

3.4 Tỷ lệ đăng ký theo tình trạng vay nhà

Bảng 3.4: Kết quả đăng ký theo tình trạng vay nhà

Vay nhà	Số bản ghi	Số đăng ký	Tỷ lệ (%)
Không (no)	5.881	3.354	57,0
Có (yes)	5.281	1.935	36,6

Hai nhóm có quy mô tương đối gần nhau, nhưng tỷ lệ đăng ký của nhóm không vay nhà cao hơn khoảng 20,4 điểm phần trăm. Đây là chênh lệch tỷ lệ trong mẫu, chưa phải mức tác động của việc vay nhà.



Hình 3.3: Tỷ lệ đăng ký theo tình trạng vay nhà

Hình 3.3 thể hiện rõ tỷ lệ 57,0% ở nhóm không vay nhà và 36,6% ở nhóm có vay. Khi thiết kế chiến dịch mới, có thể dùng khác biệt này để đặt câu hỏi thử nghiệm thông điệp phù hợp từng nhóm, thay vì xem tình trạng vay là căn cứ duy nhất chọn khách hàng.

Bảng 3.5: Kiểm định chi-square giữa vay nhà và đăng ký

Chỉ tiêu	Giá trị
Thống kê χ^2 (hiệu chỉnh Yates)	463,19
Bậc tự do	1
P-value	$9{,}72 \times 10^{-103}$
Tần số kỳ vọng nhỏ nhất	2.502,3
Mức ý nghĩa	0,05

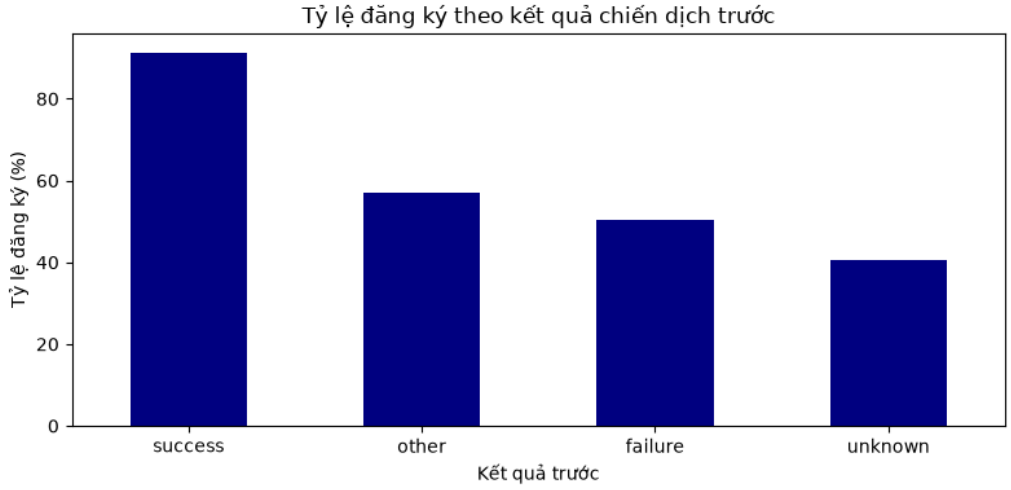
Tần số kỳ vọng đáp ứng điều kiện từ 5 trở lên. P-value nhỏ hơn 0,05 nên bác bỏ H_0. Trong mẫu có bằng chứng về mối liên hệ giữa tình trạng vay nhà và kết quả đăng ký. Bài chưa kiểm soát tuổi, thu nhập hoặc các đặc điểm khác, nên chưa thể kết luận vay nhà làm giảm khả năng đăng ký; dữ liệu cũng không có thu nhập để kiểm tra trực tiếp yếu tố này.

3.5 Kết quả campaign trước và đăng ký hiện tại

Bảng 3.6: Kết quả đăng ký theo kết quả campaign trước

Kết quả trước	Số bản ghi	Số đăng ký	Tỷ lệ (%)
`success`	1.071	978	91,3
`other`	537	307	57,2
`failure`	1.228	618	50,3
`unknown`	8.326	3.386	40,7

Nhóm `success` có tỷ lệ cao nhất, nhưng nhóm `unknown` có số đăng ký lớn nhất do quy mô lớn. Nhóm `failure` vẫn có 618 bản ghi đăng ký ở chiến dịch hiện tại, nên kết quả trước chưa quyết định hoàn toàn kết quả sau.



Hình 3.4: Tỷ lệ đăng ký theo kết quả chiến dịch trước

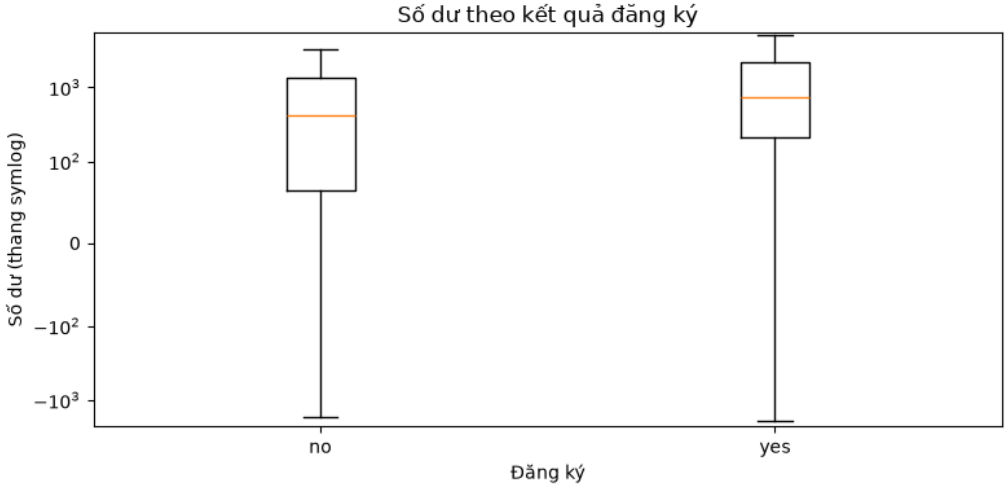
Các cột ở Hình 3.4 lần lượt giảm từ `success` đến `unknown`. Tuy nhiên, 8.324 trong 8.326 dòng `unknown` chưa được liên hệ trong chiến dịch trước. Nhóm này có lịch sử khác với các nhóm còn lại. So sánh mới dừng ở mô tả, chưa chứng minh việc liên hệ lại làm tăng tỷ lệ đăng ký. Muốn đánh giá tác động cần thử nghiệm có nhóm đối chứng trong cùng nhóm khách hàng đủ điều kiện.

3.6 Số dư theo kết quả đăng ký

Bảng 3.7: Các phân vị số dư theo kết quả đăng ký

Kết quả đăng ký	Q1	Trung vị	Q3
Không đăng ký	64	414	1.324
Đăng ký	210	733	2.159

Trung vị số dư nhóm đăng ký cao hơn 319 đơn vị so với nhóm không đăng ký. Cả Q1 và Q3 của nhóm đăng ký cũng cao hơn, nhưng hai khoảng tứ phân vị chồng lấn. Vì số dư lệch phải và có giá trị lớn, trung vị giúp mô tả vị trí trung tâm ít chịu ảnh hưởng của các điểm cực đoan hơn trung bình.



Hình 3.5: Boxplot số dư theo kết quả đăng ký

Đường trung vị của nhóm `yes` cao hơn nhóm `no`, phù hợp với Bảng 3.7. Hai boxplot vẫn có phần chồng lấn, nên riêng số dư chưa phân biệt được khách hàng đăng ký và không đăng ký. Hình dùng thang `symlog`; các điểm ngoài râu được ẩn để dễ nhìn, nhưng vẫn nằm trong tập dữ liệu phân tích. Bài chưa thực hiện kiểm định riêng cho số dư, vì vậy nhận xét ở đây là thống kê mô tả.

Chương 4. Đánh giá tác động và khuyến nghị

4.1 Tóm tắt các phát hiện

Trong 11.162 bản ghi, có 5.289 bản ghi đăng ký tiền gửi, tương ứng 47,4%. Bảng 4.1 tổng hợp các kết quả dùng để đề xuất hướng thử nghiệm. Các tỷ lệ phản ánh mẫu quan sát, chưa phải dự báo kết quả triển khai mới.

Bảng 4.1: Các phát hiện chính và ý nghĩa khi áp dụng

Yếu tố	Kết quả trong mẫu	Ý nghĩa và giới hạn
Nhóm tuổi	Trên 60 tuổi đạt 82,2%; từ 41 đến 50 đạt 40,8%.	Có thể thử thông điệp theo nhóm tuổi; nhóm trên 60 chỉ có 611 bản ghi.
Vay nhà	Không vay đạt 57,0%; có vay đạt 36,6%.	Chênh 20,4 điểm phần trăm; cần kiểm tra trên thử nghiệm trước khi mở rộng.
Kết quả trước	Nhóm `success` đạt 91,3%.	Có thể thử liên hệ lại; phần lớn nhóm `unknown` chưa được liên hệ trước đó.
Số dư	Trung vị nhóm đăng ký 733, nhóm không đăng ký 414.	Dùng thêm để mô tả nhóm; hai phân phối chồng lấn và chưa có kiểm định riêng.

Hai kiểm định về tuổi và vay nhà đều có p-value nhỏ hơn 0,05. Điều này hỗ trợ nhận định các biến có mối liên hệ trong mẫu, nhưng p-value không cho biết hiệu quả kinh tế hay chứng minh nguyên nhân. Ngân sách, số lượng khách hàng thực tế và chi phí liên hệ vẫn cần được đo thêm.

4.2 Đề xuất thử nghiệm cho chiến dịch sau

4.2.1 Thử thông điệp theo nhóm tuổi và tình trạng vay nhà

Có thể thiết kế nội dung giới thiệu sản phẩm phù hợp với từng nhóm, sau đó phân bổ ngẫu nhiên khách hàng trong mỗi nhóm vào thông điệp mới hoặc thông điệp hiện tại. Việc so sánh trong cùng nhóm giúp hạn chế nhầm khác biệt do cơ cấu khách hàng với khác biệt do thông điệp. Không dùng tuổi hoặc tình trạng vay làm căn cứ duy nhất để loại khách hàng.

Cần theo dõi số khách hàng được phân vào từng phương án, số đăng ký, tỷ lệ

đăng ký và chi phí. Nhóm có tỷ lệ cao nhưng quy mô nhỏ chưa chắc tạo ra nhiều lượt đăng ký hơn nhóm có tỷ lệ thấp và quy mô lớn. Vì vậy, không phân bổ toàn bộ ngân sách chỉ theo thứ hạng tỷ lệ trong mẫu.

4.2.2 Thử liên hệ lại khách hàng từng có kết quả thành công

Nhóm `success` có thể là đối tượng cho một thử nghiệm liên hệ lại. Chọn khách hàng đủ điều kiện trong chính nhóm này và phân bổ ngẫu nhiên vào phương án liên hệ lại hoặc phương án đối chứng đã xác định trước. Giữ cùng thời gian theo dõi và cách ghi nhận kết quả. Không dùng trực tiếp nhóm `unknown` làm đối chứng vì hai nhóm có lịch sử khác nhau.

4.2.3 Đo hiệu quả trước khi mở rộng

So sánh tỷ lệ đăng ký giữa các phương án và chi phí trên mỗi lượt đăng ký. Chỉ tiêu chi phí có thể tính bằng tổng chi phí liên hệ chia cho số lượt đăng ký; nếu không có lượt đăng ký thì chưa tính được tỷ số này. Đây là đề xuất theo dõi cho chiến dịch mới, chưa phải kết quả đã tính từ file hiện tại. Do chưa có dữ liệu chi phí và lợi nhuận, bài không khẳng định phương án nào sinh lời hơn.

4.3 Giới hạn của dữ liệu và phân tích

Dữ liệu quan sát có thể chịu sai lệch chọn mẫu. Tỷ lệ 47,4% và các tỷ lệ theo nhóm chưa chắc đại diện cho toàn bộ khách hàng ngân hàng. Bài chỉ so sánh từng yếu tố riêng, chưa kiểm soát đồng thời các đặc điểm khách hàng.

Không có mã khách hàng nên chưa xác minh được các dòng độc lập hoặc có khách hàng lặp lại. Điều này có thể ảnh hưởng đến kiểm định chi-square. Nhãn `unknown` làm hạn chế khả năng diễn giải một số thuộc tính; riêng `poutcome`, cần giữ cách phân biệt chưa được liên hệ trước với thiếu kết quả.

Ranh giới nhóm tuổi do nhóm lựa chọn phục vụ mô tả. Nếu thay đổi cách chia, kết quả theo nhóm có thể thay đổi. P-value rất nhỏ chưa nói lên độ mạnh của mối liên hệ. Các ngoại lệ được giữ nguyên có thể ảnh hưởng đến một số thống kê, nên bài đọc kèm trung vị và phân vị.

File chưa có dữ liệu chi phí, lợi nhuận hoặc thứ tự thời gian đầy đủ. Vì vậy, chưa đánh giá được hiệu quả kinh tế, biến động theo thời gian và khả năng áp dụng cho chiến dịch sau. Các giới hạn này cần được xem xét khi chuyển kết quả mô tả thành quyết định thực tế.

4.4 Hướng mở rộng và khả năng tái lập

Có thể bổ sung mã khách hàng ẩn danh để phát hiện bản ghi lặp theo người, thời điểm liên hệ để đánh giá trên giai đoạn sau và thông tin chi phí để so sánh hiệu quả. Cần kiểm tra thêm các bản ghi `unknown` và đối chiếu các giá trị cực đoan với dữ liệu gốc trước khi thay đổi cách xử lý.

Nếu phát triển mô hình dự báo trước cuộc gọi, cần loại `duration`, chia tập dữ liệu trước các phép điền thiếu hoặc mã hóa, rồi đánh giá trên tập kiểm tra độc lập. Đây là hướng mở rộng ngoài phạm vi bài hiện tại.

Notebook có chú thích từng khối xử lý và lưu bảng, hình cùng kết quả kiểm định. Nhóm đã chạy toàn bộ notebook trên Colab không báo lỗi. Khi chạy lại, dùng cùng file `bank.csv`; notebook hỗ trợ đọc file cùng thư mục, từ Drive hoặc tải lên trên Colab. Tên file notebook là `Mid-term-2-Bank-Marketing.ipynb`.

Theo yêu cầu của đề, bộ file nộp cần có notebook và PDF báo cáo trong kho GitHub công khai.

4.5 Kết luận

Bài đã kiểm tra cấu trúc và chất lượng dữ liệu, làm sạch theo các quy tắc được giải thích, trực quan hóa kết quả và kiểm định hai mối liên hệ. Trong mẫu, tỷ lệ đăng ký khác nhau theo tuổi, tình trạng vay nhà và kết quả chiến dịch trước; trung vị số dư nhóm đăng ký cao hơn nhóm không đăng ký. Những kết quả này là cơ sở đặt câu hỏi thử nghiệm. Quyết định triển khai rộng cần dựa thêm vào dữ liệu mới, nhóm đối chứng và chi phí thực tế.

TÀI LIỆU THAM KHẢO

[1] Bank Marketing Dataset, Kaggle.
https://www.kaggle.com/datasets/janiobachmann/bank-marketing-dataset.

[2] Nhóm sinh viên. *Mid-term 2: Phân tích Bank Marketing*. Jupyter Notebook trên Google Drive.
https://drive.google.com/file/d/1G0RwsGUwW5OyS5XvE6VvPzLhrBSyrju7/view?usp=sharing.

[3] Đại học Kinh tế Quốc dân. Website dạy học môn Khoa học dữ liệu.
https://fit.neu.edu.vn/smartdoc/doc/https:/github.com/NCT-NEU/Sach_Khoa_hoc_du_lieu_python/tree/main/Khoa%2520h%25E1%25BB%258Dc%2520d%E1%BB%AF%2520li%E1%BB%87u%2520c%C6%A1%2520b%E1%BA%A3n%2520trong%2520kinh%2520t%E1%BA%BF%2520v%C3%A0%2520kinh%2520doanh/?chap=1#0.